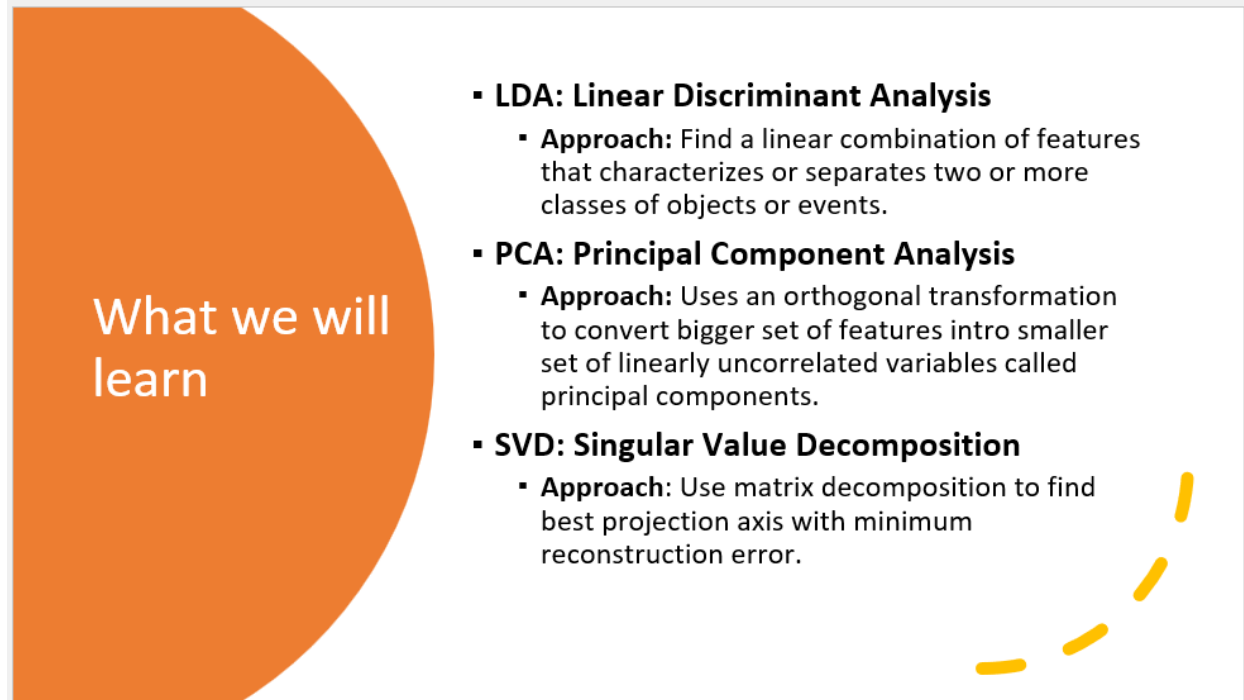


Nama : Ivan Fernanda Prayoga

NIM : 1103204035

Understanding PCA, LDA, SVD



What we will learn

- **LDA: Linear Discriminant Analysis**
 - **Approach:** Find a linear combination of features that characterizes or separates two or more classes of objects or events.
- **PCA: Principal Component Analysis**
 - **Approach:** Uses an orthogonal transformation to convert bigger set of features into smaller set of linearly uncorrelated variables called principal components.
- **SVD: Singular Value Decomposition**
 - **Approach:** Use matrix decomposition to find best projection axis with minimum reconstruction error.

LDA (Linear Discriminant Analysis)

LDA (Linear Discriminant Analysis) adalah metode analisis diskriminan linear yang digunakan untuk menemukan kombinasi linear fitur yang membedakan atau memisahkan dua atau lebih kelas objek atau lainnya. Tujuan LDA adalah untuk memaksimalkan jarak antara rata-rata kelas yang berbeda dan meminimalkan variasi dalam kelas yang sama. Oleh karena itu, LDA dapat digunakan untuk reduksi dimensi atau ekstraksi fitur dalam pengenalan pola. LDA juga dapat memberikan informasi tentang signifikansi relatif dari setiap fitur dalam memisahkan kelas, sehingga dapat membantu dalam pemilihan fitur yang paling relevan atau penting.

PCA (Principal Component Analysis)

PCA (Principal Component Analysis) adalah metode analisis komponen utama yang menggunakan transformasi ortogonal untuk mengubah himpunan fitur yang lebih besar menjadi himpunan variabel linier yang tidak berkorelasi yang disebut komponen utama. Dengan mempertahankan sebagian besar varians data, PCA berfungsi untuk mengurangi dimensi data. Komponen utama pertama memiliki variasi data yang paling besar, lalu yang kedua mengikuti setelahnya, dan seterusnya. PCA sering digunakan dalam berbagai bidang, termasuk pengolahan citra, analisis data, pengenalan pola, dan pemrosesan sinyal.

SVD (Singular Value Decomposition)

SVD (Singular Value Decomposition) adalah metode dekomposisi nilai tunggal yang digunakan untuk memecah matriks menjadi tiga matriks komponen yaitu matriks singular value, matriks singular vector kiri, dan matriks singular vector kanan. SVD dapat digunakan untuk berbagai tujuan, termasuk reduksi dimensi, kompresi data, rekonstruksi matriks, dan pemecahan persamaan linier. Dalam konteks reduksi dimensi, SVD dapat membantu mengidentifikasi sumbu proyeksi terbaik dengan kesalahan rekonstruksi minimum.